Università degli Studi di Milano Bicocca
Dipartimento di Informatica, Sistemistica e Comunicazione
Corso di Laurea Magistrale in Informatica

Analisi dei flussi ciclistici a Bologna in relazione alle condizioni meteorologiche.

Progettazione e implementazione di un Data Warehouse

Villa Emma
Matricola 885906

Contesto e Obiettivi

Negli ultimi anni Bologna ha investito nella mobilità sostenibile:

- Sviluppo ed espansione della rete di piste ciclabili
- Politiche di riduzione della CO_2
- Installazione di colonnine conta-bici

Obiettivo: Realizzare un sistema di supporto alle decisioni

- Instaurazione di nuove piste ciclabili
- Introduzione di servizi di bike sharing
  - Gestione e distribuzione delle biciclette sul territorio

Problema: per analizzare correttamente il flusso ciclistico non basta il semplice conteggio delle bici. Bisogna tenere in considerazione:

- Dimensione temporale, spaziale e condizioni meteorologiche

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Sorgenti dati

1. **Flussi biciclette**
   - Formato CSV con separatore TAB
   - Circa 350.000 record
   - Open data Bologna
2. **Dati meteorologici**
   - Formato CSV con separatore virgola
   - Circa 44.000 Record
   - API Open-Meteo
3. **Quartieri di Bologna**
   - Formato GeoJSON
   - 6 quartieri
   - Open data Bologna



Qualità dei dati e conflitti

1. **Timestamp** non uniformi
   - «data» con offset fuso orario e «time» senza offset
2. **Codici meteo** poco interpretabili per l'analisi dati
3. **Dati geografici complessi**
   - Colonnina rappresentata da un punto (longitudine, latitudine)
   - Quartiere rappresentato da un poligono
4. Il **campo area** nel JSON dei quartieri sempre nullo

1. Normalizzazione del timestamp in formato standard
2. Mappatura a descrizioni testuali
3. Join spaziale con controllo che il punto della colonnina sia dentro al poligono (ST_Within)
4. Calcolo geometrico partendo dal perimetro (ST_Area)

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Architettura del DataWarehouse

Approccio ELT: caricando i dati grezzi, per sfruttare DuckDB per le trasformazioni

1. **Livello Sorgenti:** dati esterni eterogenei
   - API Open Data Bologna e Open-Meteo
2. **Livello di alimentazione:** Integrazione e riconciliazione dei dati
   - Extract & Load: acquisizione dati e caricamento dei dati grezzi nel Raw Layer su DuckDB tramite script Python.
   - Transform: Pulizia, riconciliazione dei dati e costruzione dell'ODS tramite dbt.
3. **Livello del warehouse:** generazione delle chiavi surrogate e caricamento incrementale dei Data Mart finali.

Livello di analisi: Visualizzazione e analisi dei dati con l'utilizzo di Tableau Public.

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Analisi del carico di lavoro

Il carico di lavoro è stato definito attraverso un insieme di **interrogazioni** in linguaggio naturale a cui il sistema deve essere in grado di rispondere.

Interrogazione	**Dimensioni coinvolte**
Qual è l'andamento del traffico ciclabile totale per ogni mese dell'anno?	Dimensione Data
Qual è il quartiere della città con il maggior volume di passaggi?	Dimensione Quartiere
Quali sono le ore di punta in cui si registrano più passaggi?	Dimensione Ora
Come varia l'utilizzo della bici in caso di pioggia rispetto al tempo sereno?	Dimensione Meteo

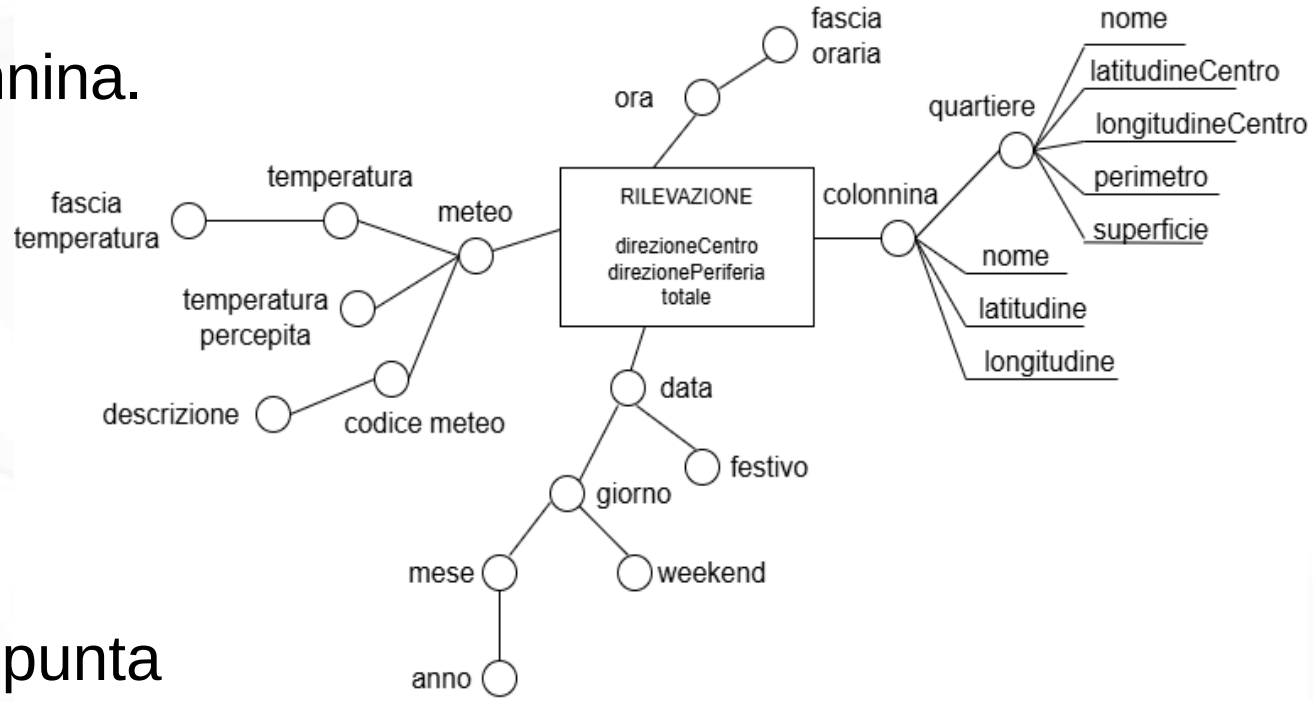
UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Progettazione Concettuale (DFM)

Fatto: Rilevazione oraria per colonnina.

Misure:

- Passaggi direzione centro
- Passaggi direzioni periferia
- Conteggio totale dei passaggi



Dimensioni:

- Oraria: Per identificare le ore di punta
- Temporale: Per analizzare la stagionalità dei flussi e il comportamento nei giorni feriali rispetto ai festivi/weekend
- Meteorologica: Per valutare quanto il clima influenzi l'utilizzo della bicicletta.
- Spaziale: Per aggregare i dati in base all'area geografica

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Schema logico e scelte implementative

- Traduzione del modello concettuale in uno **Snowflake Schema**.
- Normalizzazione delle tabelle colonnina e quartiere
  - Motivo: Evitare la ridondanza dei dati geometrici in memorizzazione.
- **Gestione dello storico:** le dimensioni soggette a cambiamenti sono colonnina e quartiere. Viene adottato SCD tipo 1.
  - Motivo: la frequenza di spostamento delle colonnine o la ridefinizione dei confini è trascurabile e l'obiettivo è supportare le decisioni sulla configurazione attuale



Pipeline ELT

- **Extractor.py:**
  - Chiamata API verso OpenData Bologna e verso Open-Meteo
  - Salvataggio dei dati grezzi sul disco
- **Loader.py:**
  - Caricamento dei dati in DuckDB utilizzando *read_csv_auto()* per i CSV e *read_json_auto()* per JSON
  - Tabelle raw create: raw_colonnine, raw_quartieri, raw_meteo
- **Trasformazione ODS con dbt**
  - *ods_x_transform.sql (materialized='ephemeral'):* Pulisce i dati, come il cast dei valori e il parsing del timestamp. Aggiunge insert_time e update_time usando current_timestamp
  - *ods_x.sql (materialized='incremental'):* materializza la tabella finale applicando la logica incrementale, filtrando quindi i nuovi record.

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Pipeline ELT

- **Alimentazione Data Mart:**
  - Si vogliono generare chiavi surrogate (SK) e gestire le foreign key.
  - *dm_x.sql :*
    - Si usa SEQUENCE di DuckDB per generare ID incrementali (tranne che per la Fact Table)
    - Si ha caricamento diretto e incrementale dall'ODS con **last execution times**, che è una tabella con i nomi dei modelli e la data della loro ultima modifica .
  - Colonnina:
    - *dm_colonnina_fk_lookup.sql (materialized='ephemeral'):* si gestisce il join spaziale tra Colonnina e Quartiere utilizzando ST_Within.
  - Fact Table Rilevazione:
    - *dm_rilevazione_fk_lookup (materialized='ephemeral'):* assembla tutte le FK dalle dimensioni.

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Gestione delle gerarchie spaziali

L’obiettivo è quello di associare ogni colonnina al quartiere in cui si trova.

Problema: i confini definiti da un poligono non sono del tutto precisi, quindi colonnine situate vicino ai confini risultavano fuori dal loro quartiere oppure in due quartieri differenti.

Soluzione: utilizzare l’estensione Spatial di DuckDB ma inserendo una tolleranza di circa 20 metri (0.0002 gradi)

$$ST_Within(ST_Point(c.longitudine, c.latitudine), oq.geom_perimetro, 0.0002)$$

Per risolvere il caso di una colonnina che risulta in più di un quartiere, si assegna la colonnina al quartiere con il centroide più vicino.

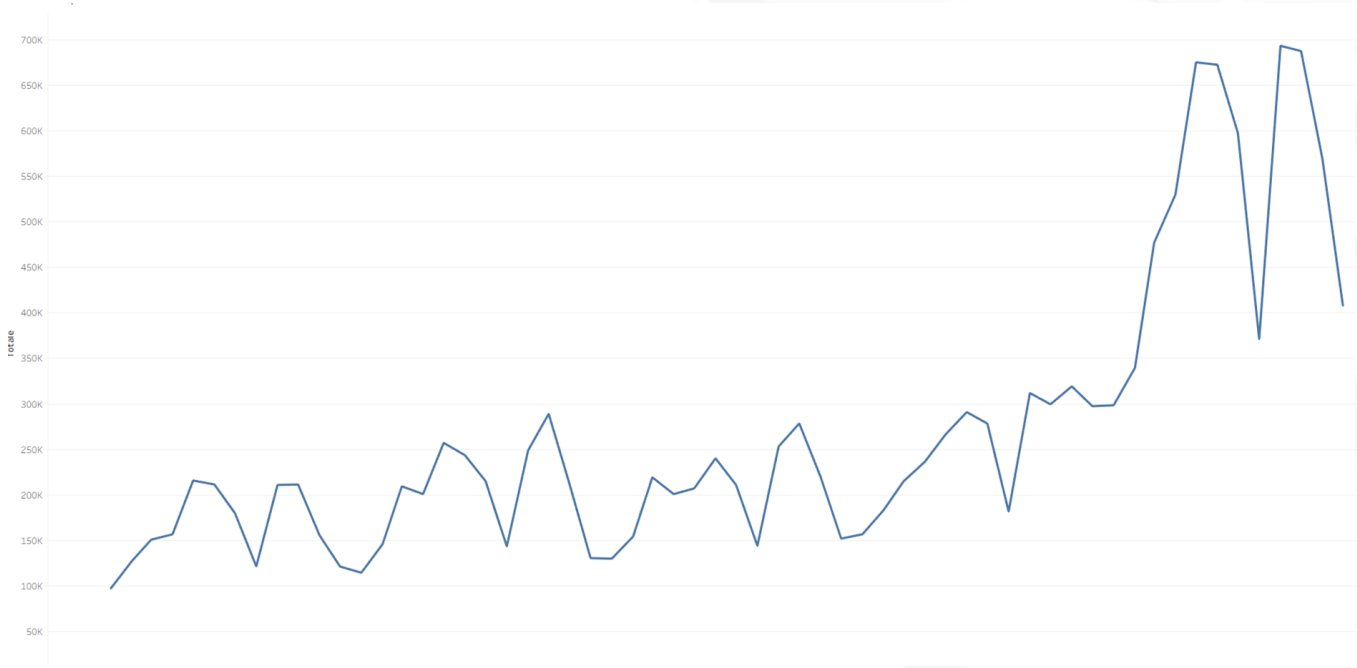
$$ST_Distance(ST_Point(c.longitudine, c.latitudine), ST_Point(dq.longitudineCentro, dq.latitudineCentro))\ as\ distanza$$

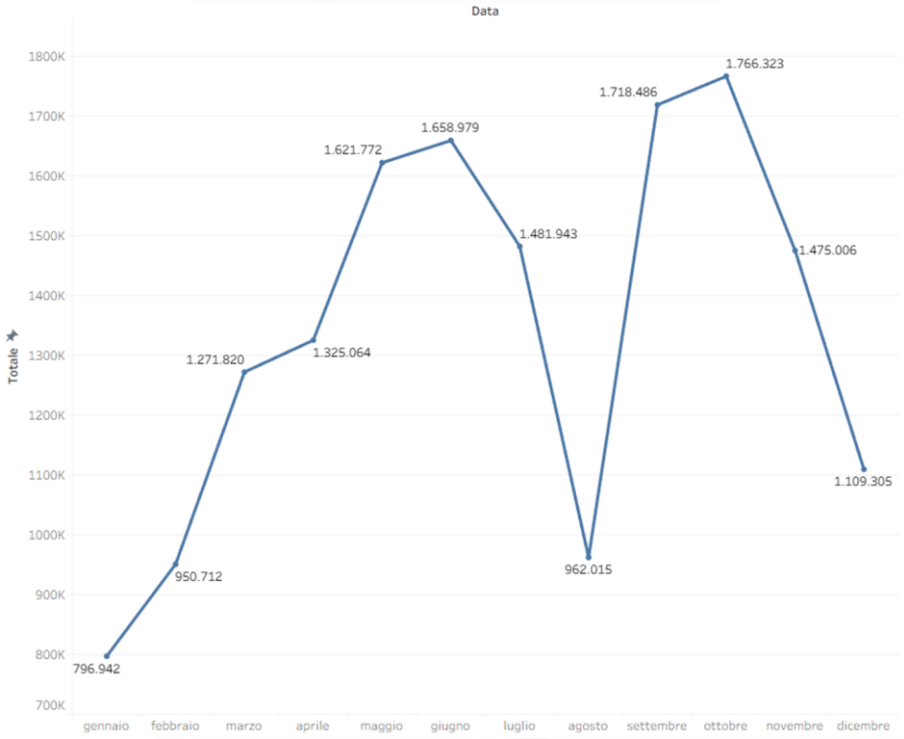
UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Analisi dei risultati

Andamento degli ultimi 5 anni

- Crescita elevata negli ultimi anni





Andamento annuale

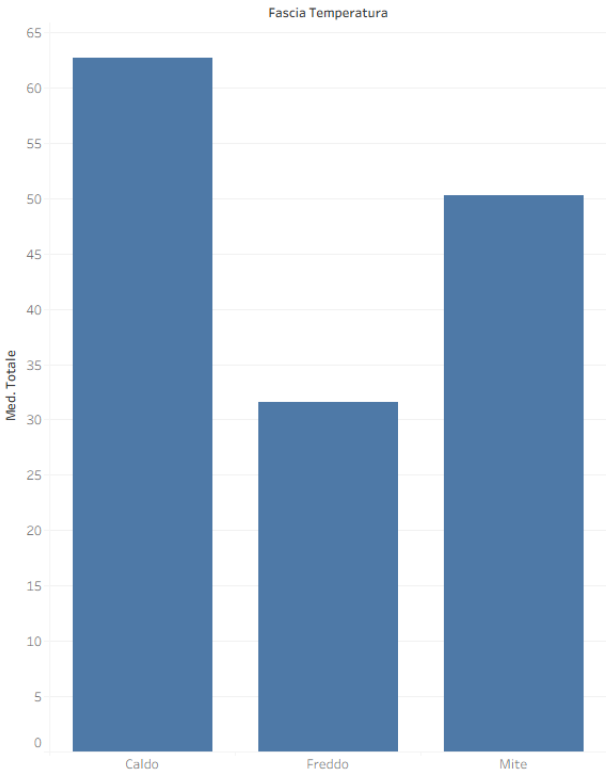
- Picchi di utilizzo in primavera e autunno, crolli in inverno e nel mese di Agosto

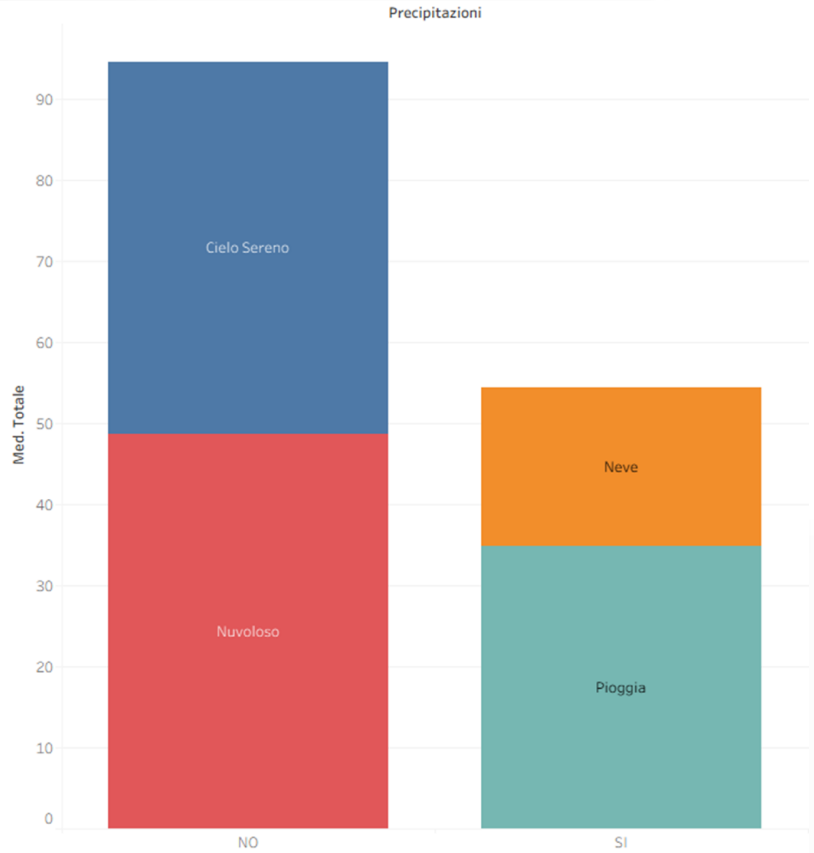
UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Analisi dei risultati

Media oraria delle rilevazioni in base alla temperatura

- Quando fa freddo °(<10°) il traffico si dimezza rispetto a quando fa caldo (> 25°)



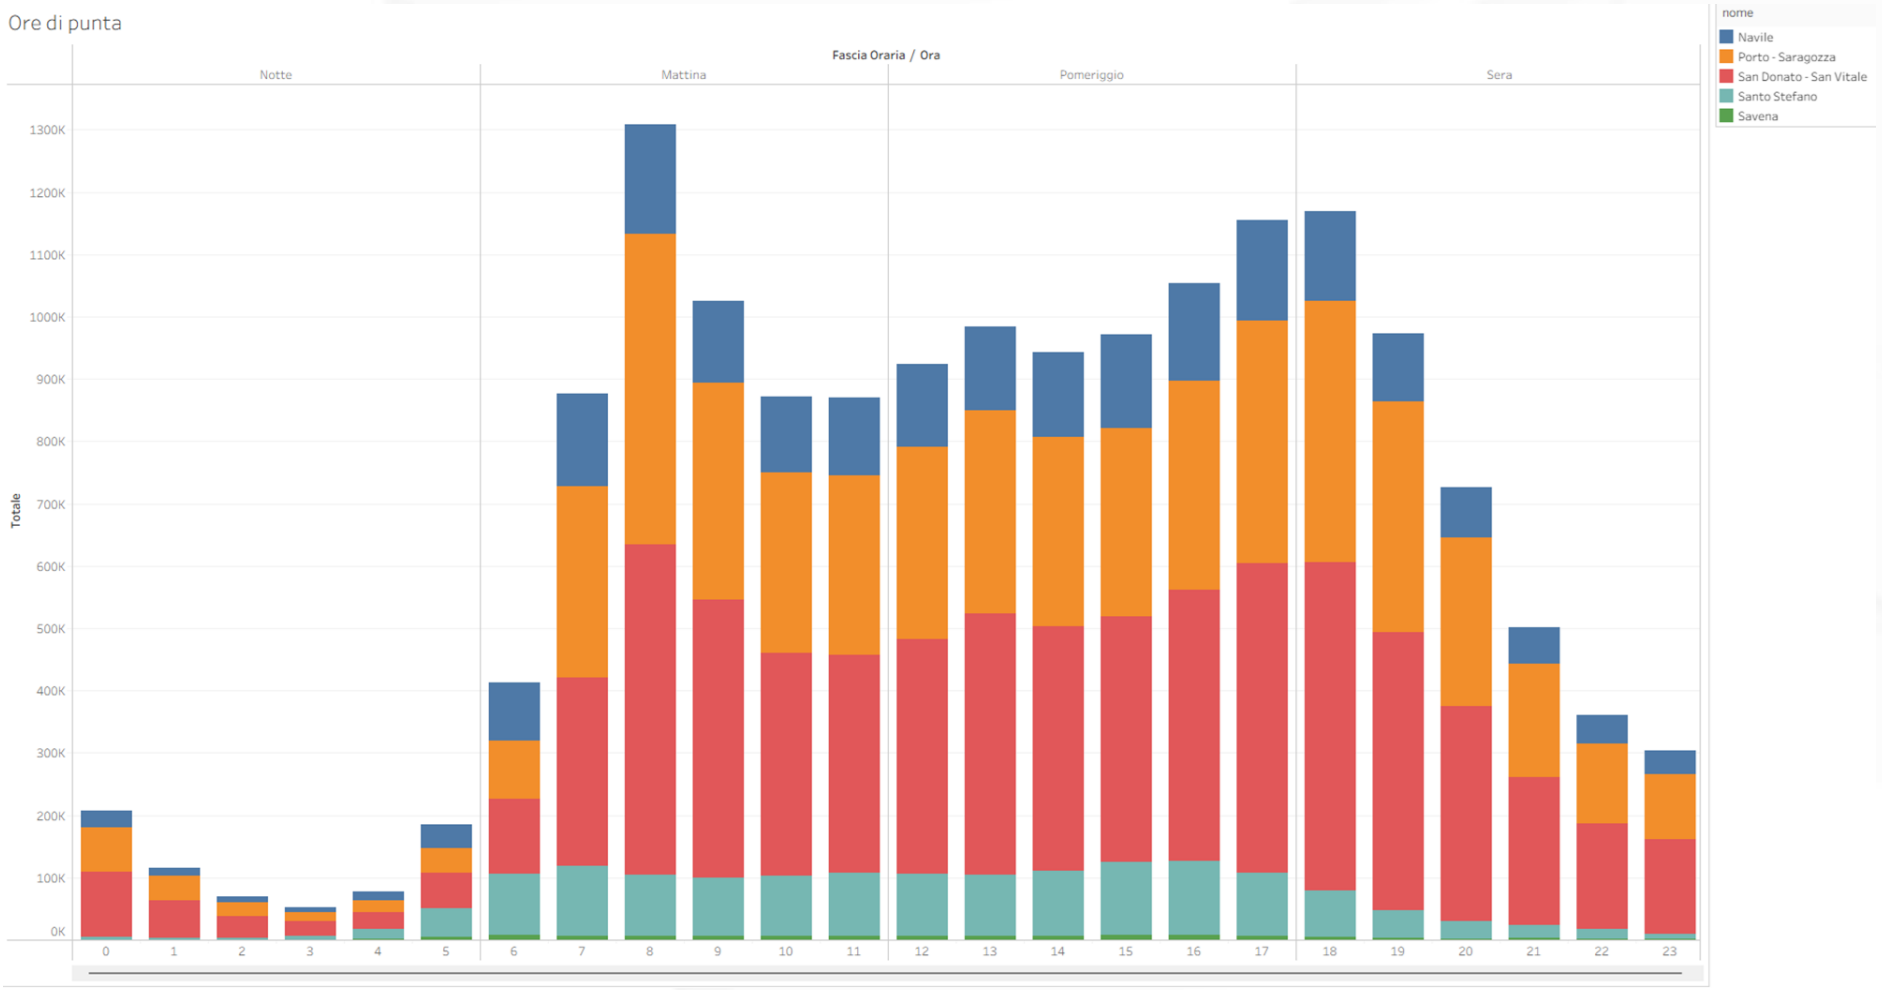


Media oraria delle rilevazioni in base a se ci sono o meno precipitazioni

- Le precipitazioni dimezzano il traffico ciclistico

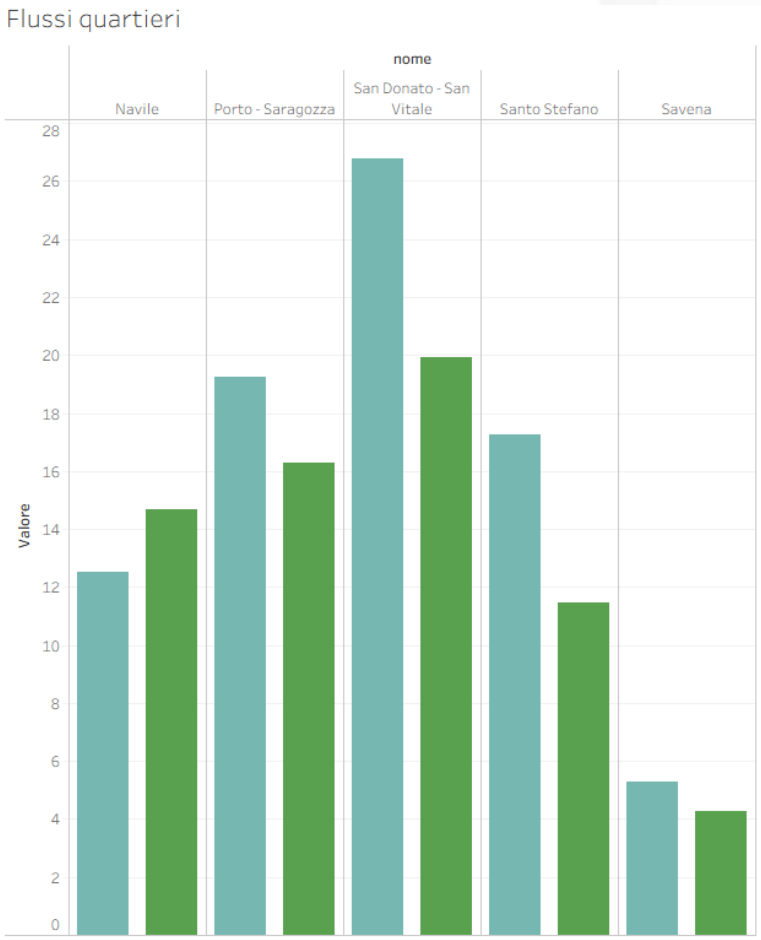
Analisi dei risultati

Analisi del flusso nelle ore di punta diviso per quartiere in cui viene generato.



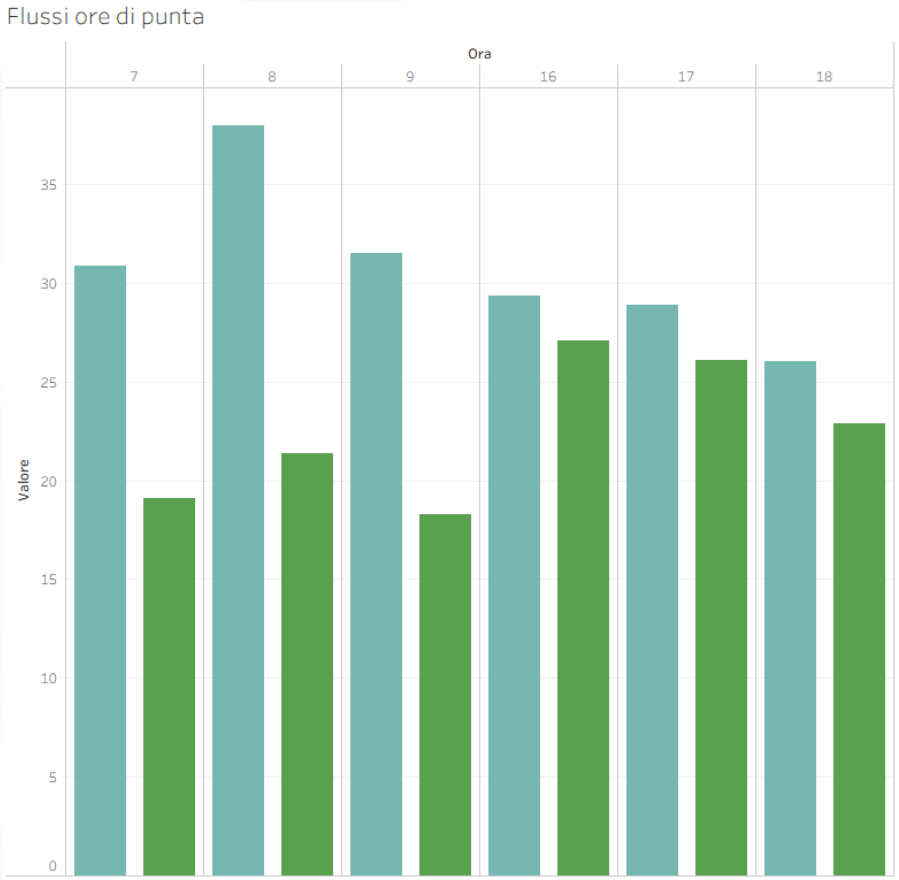
Analisi dei risultati

Media oraria delle rilevazioni divise per quartiere e per direzione



Verde acqua
→ centro

Verde scuro
→ periferia

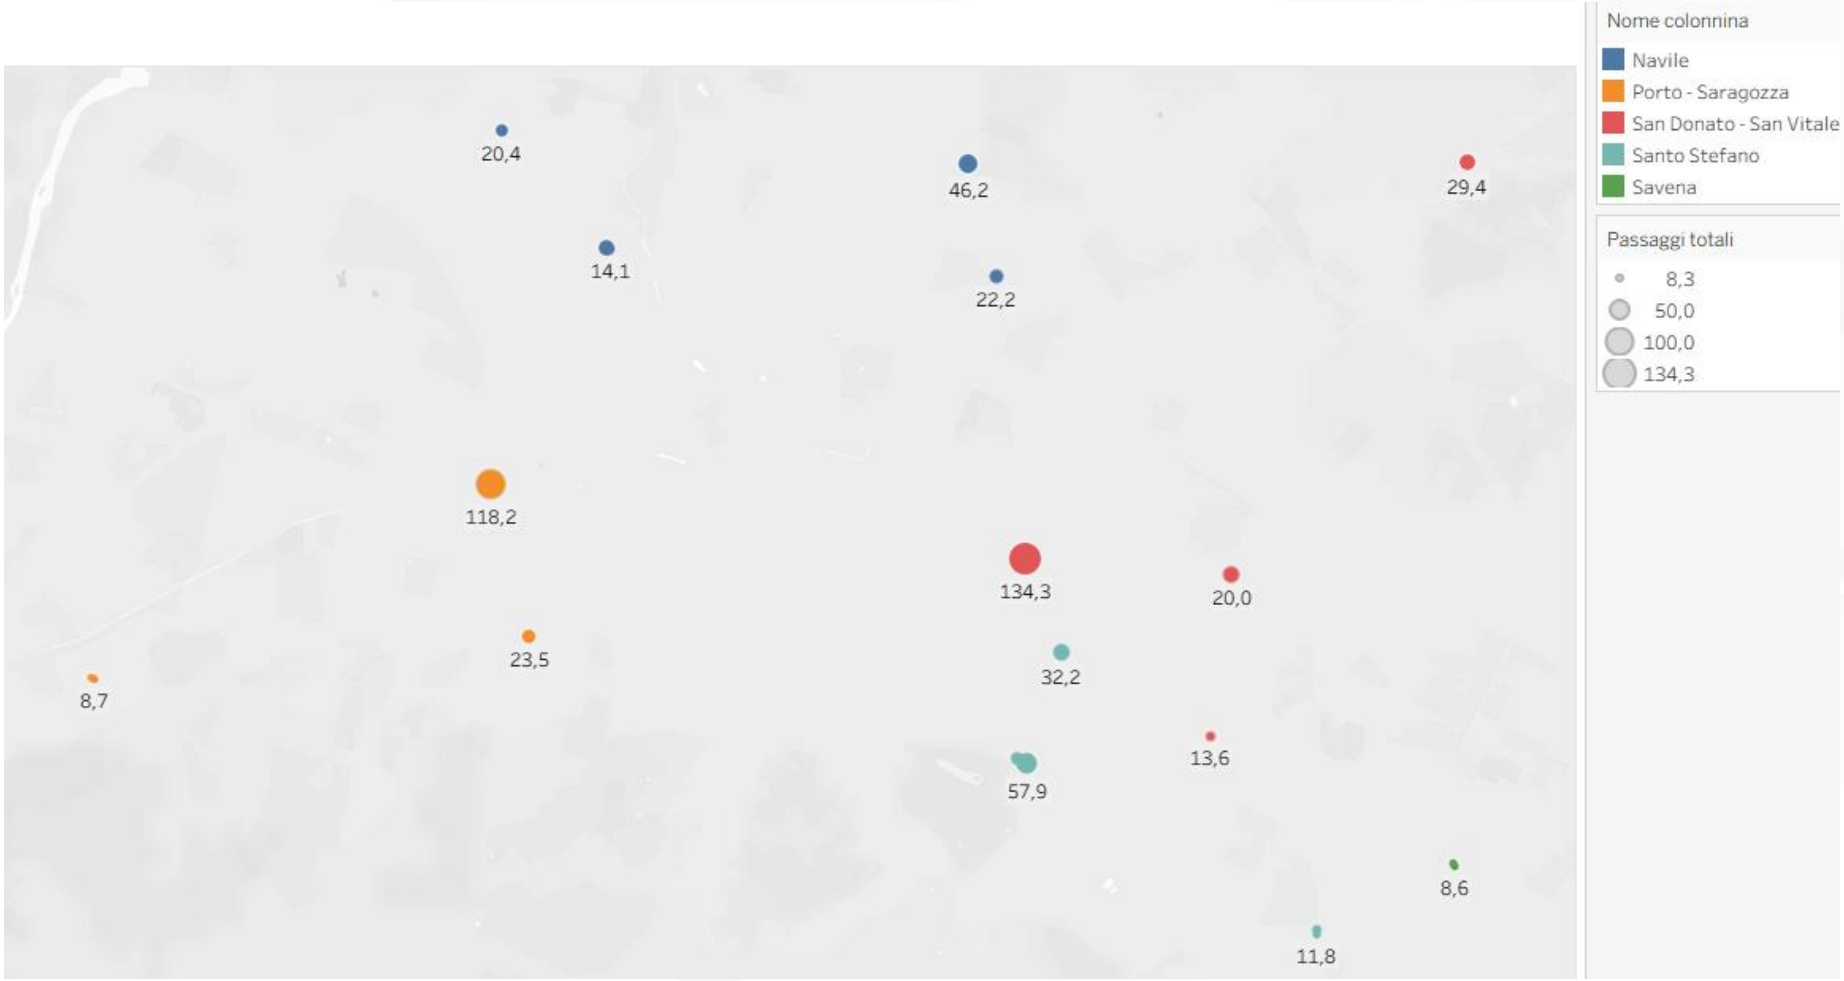


Media oraria delle rilevazioni nelle ore di punta divise per direzione

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Analisi dei risultati

Punti che rappresentano le colonnine sul territorio, divise per quartiere e di grandezza proporzionale al flusso



Conclusioni

Dall’analisi dei risultati si derivano delle raccomandazioni:

- **Espansione delle colonnine:** è necessario installare nuove colonnine nelle zone del territorio che ne sono prive
- **Aggiunta di piste ciclabili:** intensificare le piste ciclabili dove c’è un grande flusso di ciclisti.
- **Manutenzione invernale piste ciclabili:** applicare delle politiche di pulizia delle piste ciclabili in caso di ghiaccio o neve e evitare che si allaghino in caso di pioggia.
- **Pianificazione dinamica del bike sharing:** introduzione di un servizio di bike sharing con ridistribuzione delle bici nei quartieri basata sui picchi orari.

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA